Python aplicado a finanzas: fundamentos esenciales para optimizar tu portafolio

APRENDE A CALCULAR RENDIMIENTOS, RIESGO Y CREAR CARTERAS ÓPTIMAS CON CÓDIGO REAL.

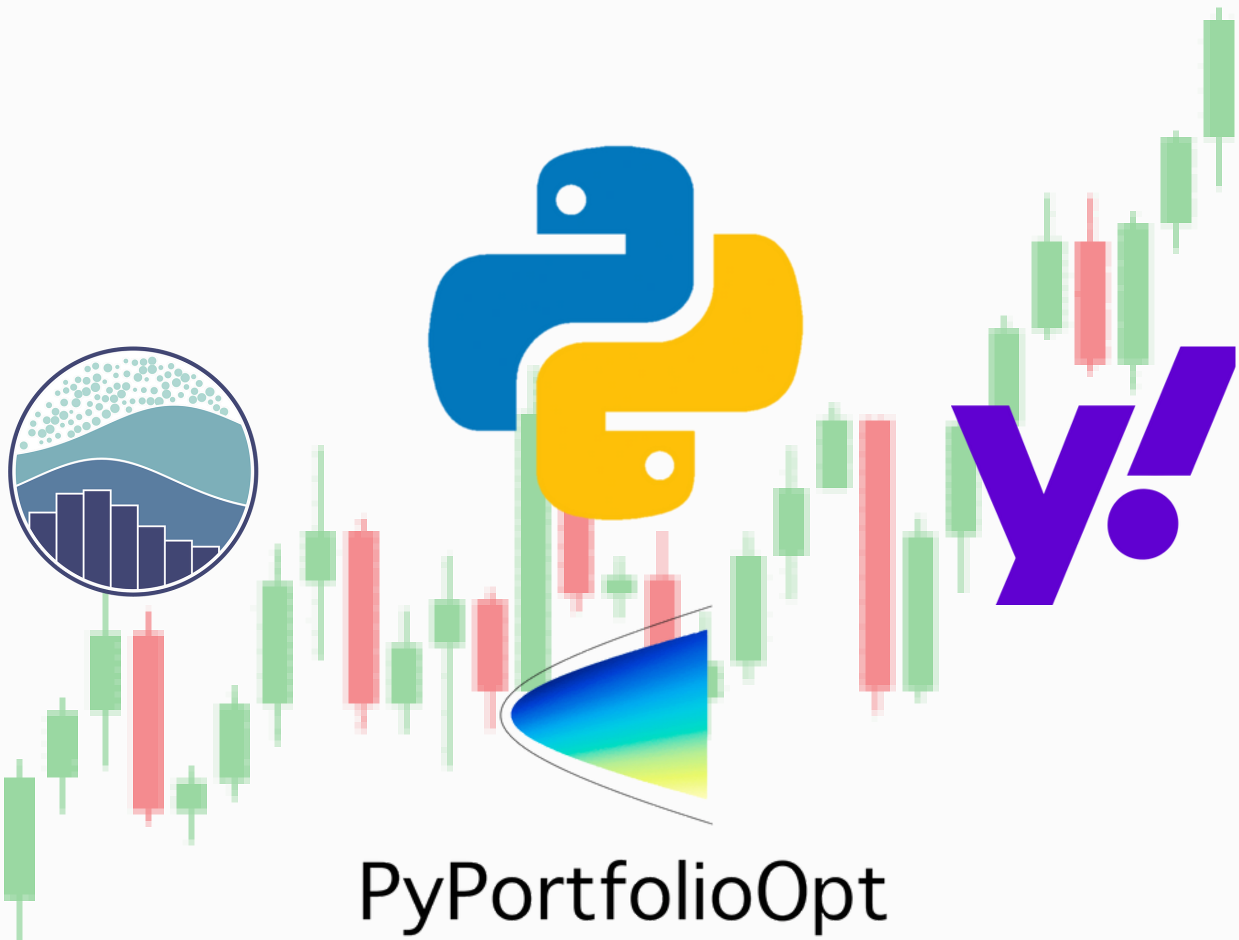

Optimiza. Diversifica. Invierte mejor.

💼Python aplicado a finanzas: fundamentos esenciales para optimizar tu portafolio💼

Autor:JoseDiego CazaresMinjares

Contacto:LinkedIn SitioWeb:betafinanciera.com

Deldato altrade: descarga,analiza, optimiza y traduce pesos a órdenes reales con pypfopt.

Objetivos breves:

- Calcular rendimientos y volatilidad.
- Construir matriz de covarianza y visualizarla.
- Dibujar la frontera eficiente y hallar el portafolio de máximo Sharpe.
- Encontrar la cartera de mínimo riesgo para un objetivo del 20% y traducirla a órdenes.
- Estimar retornos por CAPM (S&P 500) y optimizar sobre ellos; traducir la solución a órdenes.

Preparar entorno y descargar datos.

Descargar precios ajustados de los últimos 5 años para NVDA, JNJ, AAPL, JPM. Limpiar y mostrar primera vista.

```
# Importar las paqueterias necesarias
import pandas as pd import numpy as np import matplotlib.pyplot as plt import
seaborn as sns import yfinance as yf

# pypfopt
from pypfopt import expected_returns, risk_models, EfficientFrontier,
plotting
from pypfopt.discrete_allocation import DiscreteAllocation,
get_latest_prices
```

```
# Definir Activos y Periodos
tickers = ["NVDA", "JNJ", "AAPL", "JPM"]
start_date = "2020-10-01"
end_date = None     # hasta hoy

# Descarga de precios ajustados.
prices = yf.download(tickers, start=start_date, end=end_date,
auto_adjust=True)["Close"]
prices = prices.dropna(how="all")
print("Precios (últimas filas):")
print(prices.tail())
```

```
[*********************100%***********************]  4 of 4 completed

Precios (últimas filas):
Ticker            AAPL         JNJ         JPM        NVDA
Date
2025-09-30  254.630005  185.419998  313.903870  186.580002
2025-10-01  255.449997  186.050003  309.206696  187.240005
2025-10-02  257.130005  185.979996  306.061981  188.889999
2025-10-03  258.019989  188.639999  308.529999  187.619995
2025-10-06  256.690002  188.160004  309.179993  185.539993
```

Cálculo de rendimientos y volatilidad.

Convertimos precios a rendimientos simples diarios. Para cálculos anuales usamos 252 días hábiles.

Fórmula (rendimiento simple):

$$r_t = \frac{Pt}{Pt-1} - 1$$

```
# Rendimientos diarios simples
returns = prices.pct_change().dropna()
# Estadísticas básicas (anualizadas)
mu_hist = expected_returns.mean_historical_return(prices,
frequency=252)
sigma_hist = returns.std() * np.sqrt(252)
print("Rendimientos esperados (anualizados):")
print(mu_hist.round(4))
print("\nVolatilidad (anual aprox):")
print(sigma_hist.round(4))
```

```
Rendimientos esperados (anualizados):
Ticker
AAPL  0.1774
JNJ   0.0807
JPM   0.2971
NVDA  0.6885
dtype: float64

Volatilidad (anual aprox):
Ticker
AAPL  0.2863
JNJ   0.1687
JPM   0.2525
NVDA  0.5220

# Gráfica de rendimiento esperado anual
mu_hist.plot.barh(title="Rendimiento esperado anual (media histórica)")
plt.xlabel("Rendimiento esperado")
plt.tight_layout()

# Gráfica de volatilidad anual
plt.figure()

sigma_hist.plot.barh(title="Volatilidad anual aproximada")
plt.xlabel("Volatilidad (σ anual)")
plt.tight_layout()
```

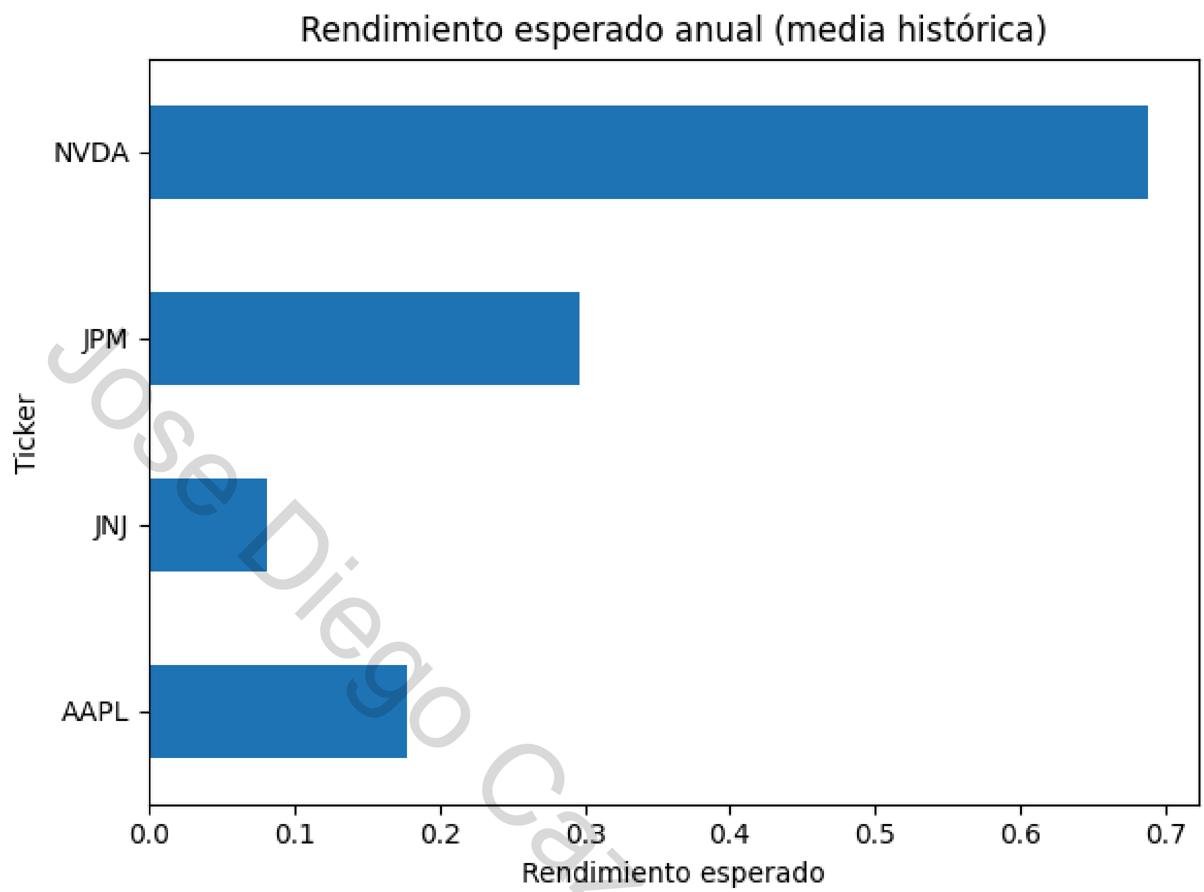
Rendimiento esperado anual (media histórica)
NVDA
JPM
JNJ
AAPL
Ticker
0.0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
Rendimiento esperado

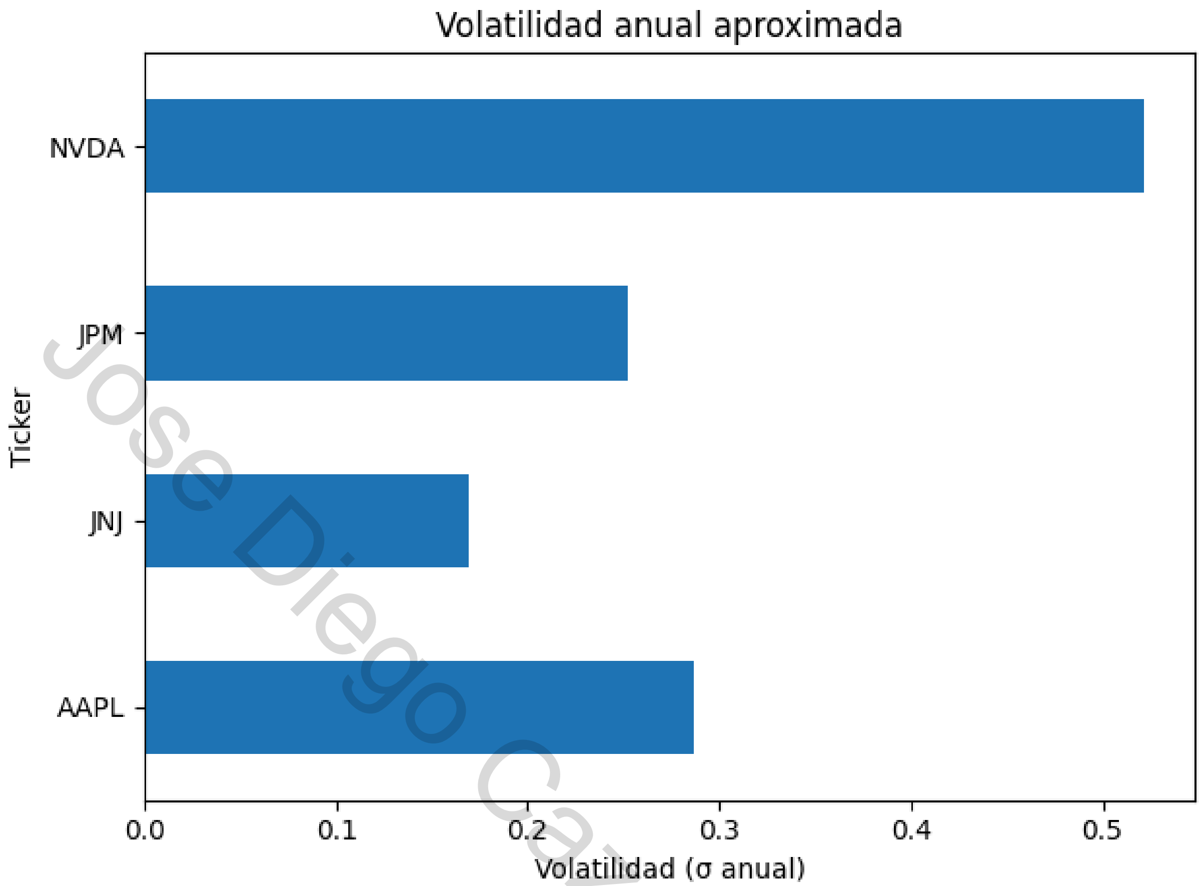

mu ofrece una guía histórica; σ cuantifica riesgo. Úsalos como punto de partida, no como verdad absoluta.

Matriz de covarianza y heatmap.

La matriz de covarianza es clave para calcular la varianza del portafolio y el efecto de diversificación.

Fórmula (varianza de portafolio):

$$\sigma_p^2 = w^\top \Sigma w$$

```
# Matriz de covarianza anualizada (sample covariance)
S = risk_models.sample_cov(prices, frequency=252)
plt.figure(figsize=(6,5))
sns.heatmap(S.round(6), annot=True, fmt=".4f", cmap="coolwarm")
plt.title("Matriz de covarianza (anualizada)")
plt.show()
```

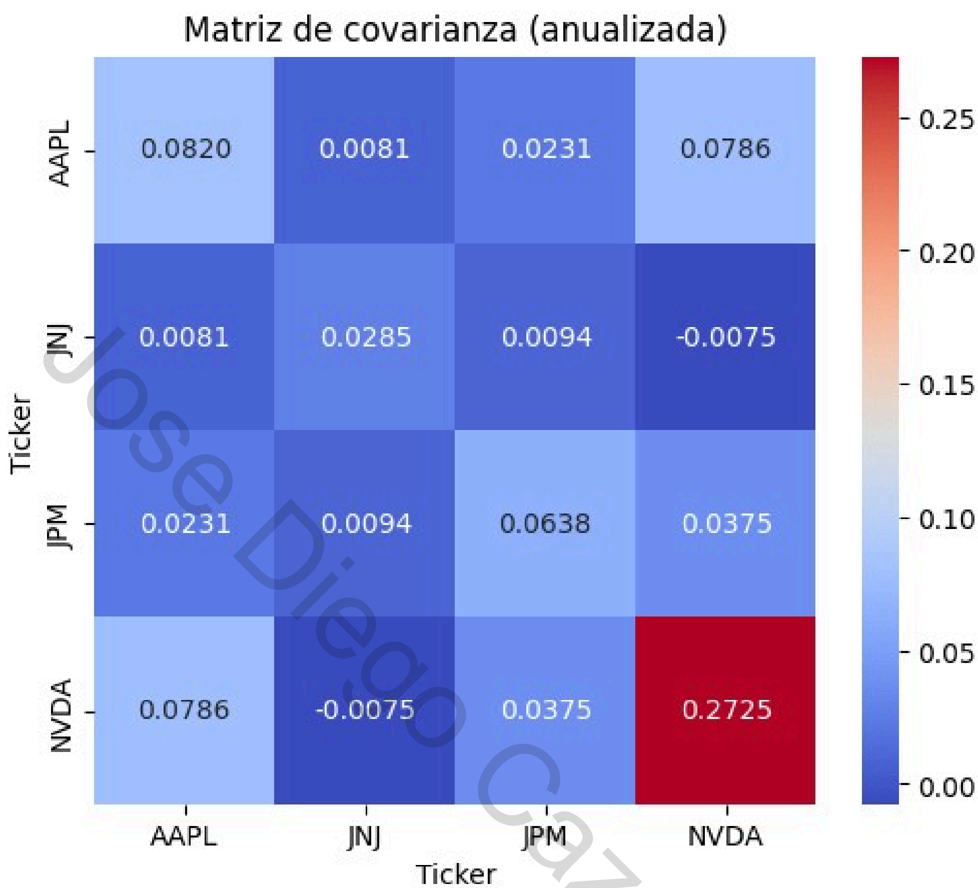

Valores altos positivos → activos se mueven juntos; negativos → se mueven en direcciones opuestas. Identifica pares con riesgo conjunto.

Frontera eficiente y portafolio de máximo Sharpe.

La frontera eficiente muestra los portafolios óptimos (mínima varianza para cada retorno). El Ratio de Sharpe compara exceso de retorno por unidad de riesgo.

Fórmula (Sharpe):

$$S = \frac{E[Rp) - R_f}{\sigma p}$$

Regla práctica de interpretación:

S > 1: excelente

0.5< S ≤1: bueno

0< S ≤0.5: modesto

S ≤ 0: bajo o negativo

```
# Construirel objeto EfficientFrontier
ef = EfficientFrontier(mu_hist, S)
risk_free_rate = 0.0416

# Encontrar la cartera de máximo Sharpe.
raw_weights = ef.max_sharpe(risk_free_rate=risk_free_rate)
weights_max_sharpe = ef.clean_weights()
print(f"Pesos (Máximo Sharpe con Rf={risk_free_rate*100}%):
{weights_max_sharpe}")

# Imprimir las métricas del portafolio óptimo.
print("\nMétricas del Portafolio Óptimo:")
ret_ms, vol_ms, sharpe_ms = ef.portfolio_performance(verbose=True,
risk_free_rate=risk_free_rate)
Pesos (Máximo Sharpe con Rf=4.16%): OrderedDict({'AAPL': 0.0, 'JNJ':
0.18068, 'JPM': 0.46374, 'NVDA': 0.35558})
Métricas del Portafolio Óptimo:
Expected annual return: 39.7%
Annual volatility: 24.9%
Sharpe Ratio: 1.43
# Graficar
from pypfopt import plotting
plt.figure(figsize=(8,6))

ef_plot = EfficientFrontier(mu_hist, S)
```

```
plotting.plot_efficient_frontier(ef_plot, show_assets=True)

plt.scatter(vol_ms, ret_ms, marker="*", s=250, c="r", label="Máximo
Sharpe")
plt.xlabel("Volatilidad (σ)")
plt.ylabel("Retorno esperado")
plt.title("Frontera Eficiente y cartera Máximo Sharpe")
plt.legend()
plt.show()
```

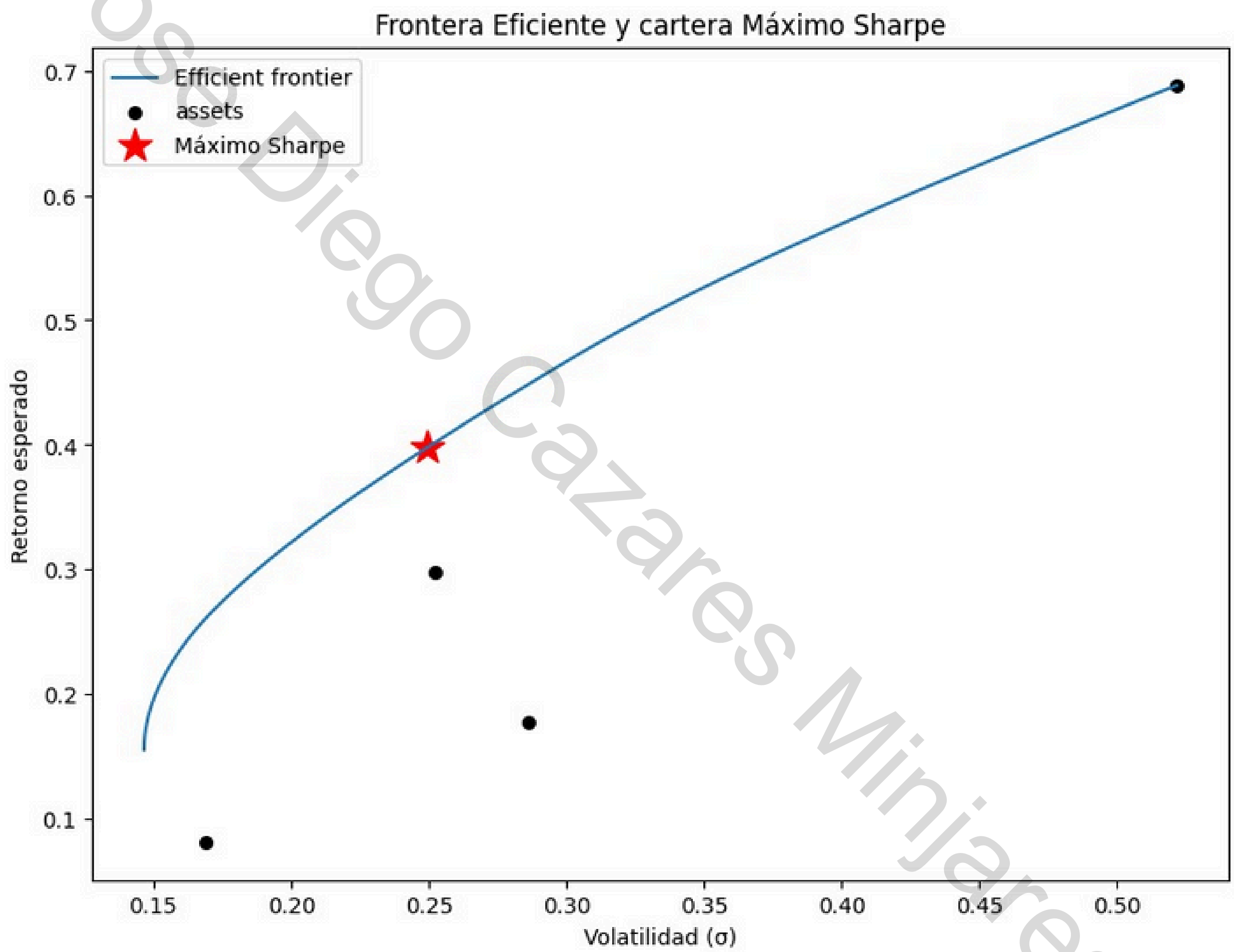

Muestra de forma visual por qué esa combinación de pesos es atractiva: máximo retorno por unidad de riesgo asumida.

Cartera mínima volatilidad para objetivo 20% y plan de compra para $10,000

Encontrar los pesos que minimizan volatilidad sujeto a un retorno objetivo anual del 20%. Luego transformamos porcentajes a órdenes para $10,000.

(Ejemplo practico)

```
# Intentar encontrar pesos para target return
target_return = 0.20

ef_target = EfficientFrontier(mu_hist, S)

try:
    weights_target =
ef_target.efficient_return(target_return=target_return)
    weights_target = ef_target.clean_weights()
    print("Pesos (mín riesgo para target 20%):", weights_target)
    ret_t, vol_t, sharpe_t =
ef_target.portfolio_perfrmance(verbose=True)
except Exception as e:
    print("No fue posible encontrar una cartera que cumpla exactamente
el target:", e)
```

```
Pesos (mín riesgo para target 20%): OrderedDict({'AAPL': 0.03939,
'JNJ': 0.62223, 'JPM': 0.23037, 'NVDA': 0.10802})
Expected annual return: 20.0%
Annual volatility: 15.1%
Sharpe Ratio: 1.33
```

```
# Distribucion del portafolio por posiciones.
latest_prices = get_latest_prices(prices)

total_value = 10000

da = DiscreteAllocation(weights_target, latest_prices,
total_portfolio_value=total_value)
allocation, leftover = da.lp_portfolio()
print("Plan de compra (inversión $10,000):")
print(allocation)
print(f"Dinero sobrante: ${leftover:.2f}")
```

```
Plan de compra (inversión $10,000):
{'AAPL': 1, 'JNJ': 34, 'JPM': 7, 'NVDA': 6}
Dinero sobrante: $68.37
```

Mostramos número de acciones por ticker y cuánto dinero queda sin invertir.

CAPM: estimar retornos esperados usando S&P 500 y optimizar Sharpe.

En vez de usar medias históricas, estimamos retornos esperados a través del CAPM, que ajusta expectativas por beta frente al mercado (S&P500).

Fórmula (CAPM):

$$E[R_i] = R_f + \beta_i (E[R_m] - R_f)$$

$$\beta_i = \frac{Cov(R_i, R_m)}{Var(R_m)}$$

```python
# Descargar S&P 500 market = yf.download("^GSPC", start=start_date, end=end_date, auto_adjust=True)["Close"]

# Rendimientos diarios

ret_assets = prices.pct_change().dropna()
ret_market = market.pct_change().dropna()


# Alinear fechas

ret_market.name = "^GSPC"
ret_data = ret_assets.join(ret_market, how="inner")
ret_assets = ret_data[tickers]
ret_market = ret_data["^GSPC"]

# Beta para cada activo

cov_with_market = ret_assets.apply(lambda x: x.cov(ret_market))
var_market = ret_market.var()
betas = cov_with_market / var_market
# Parámetros para CAPM

rf_annual = 0.0416
market_annual_return = expected_returns.mean_historical_return(market, frequency=252).iloc[0]
capm_mu = rf_annual + betas * (market_annual_return - rf_annual)
capm_mu.name = "CAPM_mu"
print("Betas:\n", betas.round(4))
print("\nRetornos esperados (CAPM, anual):\n", capm_mu.round(4))
```

```
[*********************100%***********************]  1 of 1 completed

Betas:
 Ticker
NVDA    2.1249
JNJ     0.2441
```

```
AAPL 1.2648
JPM   0.9063
dtype: float64

Retornos esperados (CAPM, anual):
 Ticker
NVDA      0.2682
JNJ       0.0676
AAPL      0.1765
JPM       0.1382
Name: CAPM_mu, dtype: float64
```

```
ef_capm = EfficientFrontier(capm_mu, S)
ef_capm.max_sharpe()
weights_capm = ef_capm.clean_weights()
print("Pesos (Max Sharpe usando CAPM mu):", weights_capm)
ret_c, vol_c, sharp_c = ef_capm.portfolio_performance(verbose=True)
```

```
Pesos (Max Sharpe usando CAPM mu): OrderedDict({'NVDA': 0.50094,
'JNJ': 0.19724, 'AAPL': 0.30182, 'JPM': 0.0})
Expected annual return: 20.1%
Annual volatility: 19.3%
Sharpe Ratio: 1.04
```

CAPM trae una expectativa teórica basada en relación con el mercado. Puede moderar o amplificar retornos según el beta particular de los ctivos.

Convertir cartera CAPM-MaxSharpeen plan decomprapara$10,000

Transformar pesos continuos a órdenes reales con presupuesto $10,000

```
# Obtener últimos precios actualizados latest_prices =
get_latest_prices(prices)

total_value_10k = 10000

da_10k = DiscreteAllocation(weights_capm, latest_prices,
total_portfolio_value=total_value_10k)
alloc_10k, leftover_10k = da_10k.lp_portfolio()
print("Plan de compra (inversión $10,000):")
print(alloc_10k)
print(f"Dinero sobrante: ${leftover_10k:.2f}")
```

```
Plan de compra (inversión $10,000):
{'NVDA': 19, 'JNJ': 10, 'AAPL': 10}
Dinero sobrante: $149.49
```

Interpretaciones prácticas y advertencias. Modelos y supuestos:

todo depende de datos históricos y supuestos
(rf, ventana, frecuencia). Revisa sensibilidad.

Target del 20%: objetivo agresivo; la solución puede implicar alta volatilidad y concentración.

DiscreteAllocation: resuelve el problema de enteros, pero puede dejar sobrante no invertido; revisa comisiones.

CAPM vs histórico: CAPM incorpora relación con mercado; puede ser más conservador si betas < 1.

Riesgo real: modelos no capturan eventos extremos (cisnes negros). Complementa con stress testing y juicio humano.

🔟 Conclusión y extensiones.

Resumen corto: Con pandas, yfinance y pypfopt puedes pasar de precios históricos a una cartera optimizada y luego a un plan de compra real con pocos bloques de código. Esto reduce la fricción entre análisis y ejecución.

Extensiones recomendadas:

Backtesting de rebalanceos periódicos.

Optimización con restricciones (límites por activo/sector, ESG).

Uso de métricas alternativas (Sortino, drawdown constraints).

Simulaciones Monte Carlo y stress tests.

Descargo de responsabilidad: Este artículo es puramente informativo y no constituye asesoramiento financiero. No se
recomienda tomar decisiones de inversión basadas únicamente en esta información. Se aconseja
realizar un análisis propio y consultar a un profesional financiero antes de tomar decisiones de
inversión. Las decisiones de inversión son responsabilidad exclusiva del lector.
En todo momento se incita a hacer un análisis propio, y saber que tus decisiones son completamente tuyas y afectan tus inversiones y tu patrimonio.

- No es una asesoría financiera.
- No supone en ningún caso, esto sea recomendación de inversión, de compra o de venta de ningún activo/bien o subyacente.
- El contenido del articulo es meramente informativo.
- En todo momento se incita a hacer un análisis propio, y saber que tus decisiones son completamente tuyas y afectan tus inversiones y tu patrimonio.